Universidade Federal de São João del-Rei
Pró-Reitoria de Pesquisa e Pós-Graduação
Edital nº 008/2026/PROPE/PROAE - Comprovante de Inscrição

Programa: PIBIC (com bolsa)

Dados Pessoais	
Nome: ROBSON BRUNO DUTRA PEREIRA	**CPF:** 014.325.396-47
Data de Nascimento: 04/09/1984	**Identidade:** MG12071924 SSP/MG
Endereço: AVENIDA ANTONINA DE ALMEIDA NEVES N§ 543	**CEP:** 36302600
Bairro: SOLAR DA SERRA	**Cidade/UF:** SAO JOAO DEL-REI / MG
Unidade Organizacional: 2.12.00.00 - Departamento de Engenharia Mecânica e Produção	
E-mail Institucional: robsondutra@ufsj.edu.br	
E-mail 2: -	**E-mail 3:** -
URL do Currículo Lattes: http://lattes.cnpq.br/6576147125211659	
Área de Atuação: Engenharia de Produção	
Laboratório: CIMOS	**Fax:** -
Telefone 1: (32)9145-9679	**Telefone 2:** (32)3379-2606
Titulação Máxima: Doutor	**Ano / País / Instituição da Titulação:** 2017 / Brasil / Universidade Federal de Itajubá
Possui Bolsa de Produtividade em Pesquisa (PQ) ou Bolsa de Produtividade em Desenvolvimento Tecnológico e Extensão Inovadora (DT): Não	
Área de Conhecimento 1 para atuação como parecerista *ad hoc*: Engenharia de Produção (Engenharias)	
Área de Conhecimento 2 para atuação como parecerista *ad hoc*: Engenharia Mecânica (Engenharias)	
Área de Conhecimento 3 para atuação como parecerista *ad hoc*: Probabilidade e Estatística (Ciências Exatas e da Terra)	

Dados do Projeto	
Código: 31284	
Título: Previsão hierárquica de tráfego de veículos em rodovias brasileiras	
Data de Início: 01/09/2026	**Data de Término:** 31/08/2027
Palavra-Chave 1: Monitoramento de tráfego	**Palavra-Chave 2:** Séries temporais hierárquicas
Palavra-Chave 3: Reconciliação de séries temporais	**Palavra-Chave 4:** -
Palavra-Chave 5: -	**Palavra-Chave 6:** -
Grande Área: Engenharias	**Área:** Engenharia de Produção
O tema do Projeto é *Tecnologias, Práticas e Gestão na Educação à Distância*? Não	

***Template* do Projeto**

Introdução:

'A violência da noite, o movimento do tráfego... Amar e mudar as coisas me interessa mais' Belchior

As rodovias desempenham um papel importante na vida urbana moderna, uma vez que promovem acessibilidade, melhoram conectividade, reduzem congestionamentos, apresentando impacto econômico significativo (ABBASI et al., 2025; YUAN et al., 2011; ZHOU et al., 2019). Com o progresso e o desenvolvimento da civilização, bem como expansão das cidades, observa-se um número crescente de veículos motorizados e volume de tráfego nas vias. À medida que os fluxos de tráfego continuam a aumentar e as vias urbanas se expandem, o planejamento urbano precisa ser aprimorado e adaptado (YANG & WANG, 2023).

Como impacto negativo do aumento volume de tráfego observa-se o aumento do número de acidentes, aumento de emissões, mudança no comportamento e dinâmica de comunidades, alterações em áreas naturais circundantes, acarretando mortalidade de animais e alteração da dinâmica destes mesmo a quilômetros de distância da estrada (YAMASHITA et al., 2025; ZENG et al., 2025).

O volume de tráfego de veículos em rodovias é apontado como uma das principais causas de acidentes de trânsito, além da velocidade de circulação, tipo de via, condições climáticas e infraestrutura viária (SILVA et al., 2026; YANG & WANG, 2023; PEDEN, 2004; ELVIK & AMUNDSEN, 2004). O volume de tráfego, além do tipo de via e máxima velocidade permitida são também apontados como fatores que afetam a velocidade de tráfego e o comportamento dos condutores (SILVA et al., 2024). Ademais, o volume de tráfego, em instantes distintos de tempo, também pode ser útil à previsão da velocidade de tráfego (GAO et al., 2022).

Como componente indispensável dos sistemas de transporte inteligentes, a previsão do volume de tráfego tem recebido enorme atenção nas últimas duas décadas, sendo um tema atual e significativo de investigação (SUN et al., 2021), além de amplamente empregado para formulação de políticas públicas de transportes, planejamento e desenvolvimento da logística de cargas, controle de tráfego, redução de emissões e orientação ao público (GAO et al., 2024; YANG & WANG, 2023; DING et al., 2023; LU et al., 2023; YANG et al., 2022; ZHENG & SU, 2014).

A melhoria contínua dos serviços de tráfego torna a rede rodoviária circundante mais atraente, acarretando aumento repentino no volume de tráfego rodoviário em um curto período de tempo (Yang e al., 2022). Sistemas de transporte inteligentes são imprescindíveis no âmbito rodoviário para orientação do tráfego e planejamento de viagens (YUAN et al., 2011; ZHOU et al., 2019). Com o rápido desenvolvimento de tecnologias como Big Data e Internet das Coisas, diversos dados de trânsito têm sido acumulados e disponibilizados em acesso aberto (DING et al., 2023).

Diversos estudos têm sido realizados aplicando métodos distintos para previsão e controle de tráfego, tais como redes neurais convolucionais e de memória de curto prazo (LSTM) (DING et al., 2023; GAO et al., 2024; YANG et al., 2022; YANG et al., 2023), modelos de machine learning como Reforço por gradiente extremo (XGBoost) (LU et al., 2023; SUN et al., 2021) e k- vizinhos mais próximos (ZHENG et al., 2014); fusão de dados considerando GPS, apps de mobilidade (Eisinga & Lorkowski, 2025); entre outras abordagens.

Apesar do volume de tráfego ser heterogêneo em termos de classes e tipos de veículos, sentido de circulação, quilômetro e rodovia específica, foram observados poucos estudos que contemplem a modelagem e previsão hierárquica, no sentido de garantir a reconciliação de séries temporais e previsões coerentes em todos os níveis hierárquicos. É importante destacar que o termo hierárquico é comumente encontrado em trabalhos de previsão de volume de tráfego, porém não se referindo à estrutura hierárquica do tráfego, mas sim relacionados à arquitetura do método ou modelo utilizado (QIN et al., 2023; MU et al., 2023; JI et al., 2025; CHE et al., 2026; XIA et al., 2026).

Uma série temporal hierárquica refere-se a um conjunto de séries temporais que podem ser agregadas a diferentes níveis, de acordo com uma estrutura hierárquica bem definida (LILA et al., 2022). A literatura demonstra que as previsões geradas de forma independente em cada nível hierárquico tendem a ser mutuamente incoerentes, limitando a sua aplicabilidade em processos reais de planeamento energético e industrial (REHMAN et al., 2023). Por conseguinte, os métodos de previsão hierárquica destacaram-se como uma alternativa para obter maior precisão no processo de previsão e, neste sentido, as aplicações relacionadas com a energia têm sido exploradas em vários domínios, incluindo estudos relacionados com a produção, distribuição e consumo (STOIAN et al., 2025).

De acordo com Lila et al. (2022), num contexto de previsão hierárquica, as previsões são inicialmente geradas de forma independente para todas as séries utilizando um método de previsão predefinido, resultando em previsões de base. Uma vez que estas previsões são produzidas sem impor

restrições de agregação, podem ser mutuamente inconsistentes. É então aplicado um procedimento de reconciliação ótimo para combinar e ajustar as previsões de base, a fim de obter um conjunto final de previsões coerentes. A coerência implica que as previsões satisfazem a estrutura de agregação hierárquica, mantendo-se imparciais e apresentando uma variância mínima entre todas as combinações viáveis. A lógica subjacente à reconciliação é que a revisão conjunta de previsões produzidas de forma independente permite, pelo menos em teoria, estimativas mais precisas e estatisticamente eficientes do processo subjacente do que as obtidas apenas a partir de métodos de previsão independentes.

Por conseguinte, os métodos de reconciliação de previsões surgem como ferramentas essenciais para garantir a coerência estatística entre os diferentes níveis hierárquicos, reduzindo simultaneamente a variância dos erros de previsão. Por outras palavras, a reconciliação de previsões garante que as previsões de séries temporais dentro de uma estrutura hierárquica sejam consistentes com as restrições de agregação, apoiando assim uma tomada de decisão coordenada e coerente (WANG et al., 2025). Evidências empíricas indicam que abordagens como a abordagem baseada no traço mínimo superam as estratégias de previsão tradicionais em aplicações industriais e energéticas, inclusive no contexto brasileiro (CABREIRA, 2024). Estudos em grande escala demonstram ainda que esses ganhos de desempenho permanecem significativos mesmo em hierarquias extensas com séries temporais esparsas nos níveis mais desagregados (KAMARTHI et al., 2024).

O Departamento Nacional de Infraestrutura de Transportes (DNIT) realiza desde 1975 o Plano Nacional de Contagem de Tráfego (PNCT), apresentando atualmente cobertura expressiva de diversos quilômetros das rodovias mais importantes do país. Tais dados são importantes para ações de planejamento, projetos rodoviários e estudos econômicos (DNIT, 2026).

Objetivos:

Neste trabalho pretende-se aplicar métodos de reconciliação de séries temporais hierárquicas para prever o volume de tráfego em rodovias do país. A estrutura hierárquica dos dados do DNIT será explorada de forma a não somente prever o volume de fluxo agregado, mas também, desagregado por segmento e tipo de veículo, além de considerar o sentido de circulação, rodovias e quilômetros selecionados.

Como objetivos específicos pretende-se:
- Definir rodovias e quilômetros críticos, com alta circulação, para serem estudos;
- Testar distintos métodos de reconciliação de séries temporais hierárquicas para realizar previsões coerentes, tais como mínimos quadrados ordinários (OLS), traço mínimo (MinT) e mínimos quadrados ponderados (WLS);
- Testar distintos métodos de previsão base (os métodos hierárquicos são agnósticos em relação às previsões base, podendo ser testados métodos distintos), os quais tenham capacidade de modelar complexos padrões sazonais, tais como seasonal and trend decomposition by LOESS (STL); Trigonometric, Box-Cox transformation, ARMA errors, Trend e Seasonal components (TBATS); regressão dinâmica harmônica, entre outros.
- Avaliar quais melhores métodos base e de reconciliação apresentam melhor desempenho nas previsões coerentes;
- Divulgar os resultados para o público acadêmico e para os departamentos de trânsito.

Metodologia:

Os dados utilizados são disponibilizados pelo PNCT (DNIT, 2026). Os dados consistem na contagem de veículos com frequência horária em diversas categorias para os dois sentidos de circulação, distintas rodovias e quilômetros. Há quilômetros com anos de observação, favorecendo a análise da sazonalidade diária, semanal e anual. Os dados apresentam sazonalidade diária, devido ao maior fluxo durante as horas de sol e drástica redução durante a noite; semanal, devido a redução no volume de fluxo nos fins de semana para boa parte das categorias de veículos; e anual devido aos feriados.

A herarquia será estabelecida em dois níveis: volume total de circulação, volume por classe: 2 a 9 eixos, veículos de passeio, utilitários e motos; e volume por tipo específico (desagregando as classes) Tais classes incluem os seguintes tipos de veículos: Ônibus, Caminhão Simples (2 eixos); Ônibus, Caminhão Simples, Caminhão Semirreboque (3 eixos); Caminhão Simples, Caminhão + Semirreboque, Caminhão + Reboque, Caminhão + 2 Semirreboques (4 eixos); Caminhão + Semirreboque, Caminhão + Reboque, Caminhão + Semirreboque + Reboque, Caminhão + 2 Semireboques (5 eixos); Caminhão + Semirreboque, Caminhão + Reboque, Caminhão + Semirreboque + Reboque, Caminhão + 2 Semirreboques (6 eixos); Caminhão + Reboque, Caminhão + 2 Semirreboques, Caminhão + Semirreboque + Reboque, Caminhão + 2 Reboques, Caminhão + 2 Semirreboques (7 eixos); Caminhão + 2 Semirreboques, Caminhão + Semirreboque + Reboque, Caminhão + 2 Reboques (8 eixos); Caminhão + 2 Semirreboques, Caminhão + Semireboque + Reboque, Caminhão + 3 Semirreboques (9 eixos); Veiculos de passeio e utilitários e Motocicletas. As séries serão consideradas desagrupadas por sentido de circulação.

Serão considerados os métodos de reconciliação OLS, WLS (HYNDMAN et al., 2011), MinT (WICKRAMASURIYA et al., 2019) e variantes. No apêndice, anexado como figura, são detalhados os métodos de reconciliação a serem testados. Pretende-se testar como métodos base o STL (Cleveland et al., 1990), TBATS (Hyndman et al., 2011) e regressão dinâmica harmônica (Hyndman & Athanasopoulos, 2021).

Será realizada validação cruzada via rolling forecasting origin, de forma a mensurar quais métodos têm melhor consistência para distintas janelas de previsão de curto e médio prazo.

Para modelagem, serão utilizadas as linguagens R e, se necessário, python. A linguagem R apresenta pacotes mais desenvolvidos para séries temporais hierárquicas.

Plano de Trabalho:

A seguir é especificado o plano de trabalho do bolsista de iniciação científica.
- Revisão bibliográfica e estudo teórico sobre séries temporais hierárquicas, métodos para previsão de sazonalidade complexa e literatura sobre modelagem de volume de tráfego e aplicações (meses 1 a 12);
- Estudo das rodovias e trechos mais críticos e definição das condições de contorno do estudo (meses 2 a 4);
- Aquisição, leitura e tratamento dos dados (meses 3 a 5);
- Visualização gráfica das séries agregadas e desagregadas, de forma padrão e sazonal (meses 3 a 6);
- Programação do loop de validação cruzada para as distintas abordagens de reconciliação e distintos métodos base (meses 4 a 8);
- Avaliação do desempenho dos melhores métodos de reconciliação e base (meses 5 a 9);
- Realização de previsões com os métodos de melhor desempenho (meses 7 a 10);
- Conclusões e divulgação aos departamentos de trânsito (publicação online de modelos e resultados) (meses 9 a 11);
- Escrita de artigos e relatório (meses 7 a 12).

Referências:

Abbasi, M., Bilal, M. T., Consilvio, A., Giglio, D., Sacco, N., & Arevalo, P. L. (2025). On minimizing the impact on traffic of maintenance work zones in a highway network. Transportation Engineering, 100381.

Athanasopoulos, G., Hyndman, R. J., Kourentzes, N., & Petropoulos, F. (2017). Forecasting with temporal hierarchies. European Journal of Operational Research, 262(1), 60-74.

Cabreira, M. M. L., Silva, F. L. C., Cordeiro, J. S., Ureta Tolentino, J. M., Carbo&8208;Bustinza, N., Canas Rodrigues, P., & López&8208;Gonzales, J. L. (2024). Comparison between hierarchical time series forecasting approaches for the electricity consumption in the brazilian industrial sector. Applied Stochastic Models in Business and Industry.

Che, C., Wang, H., Li, Z., & Li, H. (2026). Decoupled spatiotemporal bidirectional diffusion Informer for long short-term traffic flow forecasting. Applied Mathematical Modelling, 116882.

Cleveland, R. B.; Cleveland, W. S.; Mcrae, J. E.; Terpenning, i. STL: A seasonal-trend decomposition procedure based on loess. Journal of Official Statistics, v. 6, n. 1, p. 3?73, 1990.

Departamento Nacional de Infraestrutura de Transportes (DNIT). Plano Nacional de Contagem de Tráfego (PNCT) ? Mapa de dados. Disponível em: https://servicos.dnit.gov.br/dadospnct/mapa. Acesso em: 10 abr. 2026.

Ding, W., Zhang, T., Wang, J., & Zhao, Z. (2023). Multi-graph Spatio-temporal Graph Convolutional Network for Traffic Flow Prediction. arXiv preprint arXiv:2308.05601.

Eisinga, K., & Lorkowski, S. (2025). Network-wide traffic volume estimation based on probe vehicle data. Transportation Research Record, 2679(4), 264-277.

Elvik, R., Christensen, P., & Amundsen, A. (2004). Speed and road accidents. An evaluation of the Power Model. TØI report, 740(2004), 114-122.

Gao, H., Jia, H., Huang, Q., Wu, R., Tian, J., Wang, G., & Liu, C. (2024). A hybrid deep learning model for urban expressway lane-level mixed traffic flow prediction. Engineering Applications of Artificial Intelligence, 133, 108242.

Gao, Y., Zhou, C., Rong, J., Wang, Y., & Liu, S. (2022). Short-term traffic speed forecasting using a deep learning method based on multitemporal traffic flow volume. IEEE Access, 10, 82384-82395.

Hyndman, R. J.; Ahmed, R. A.; Athanasopoulos, G.; Shang, H. L. Optimal combination forecasts for hierarchical time series. Computational Statistics & Data Analysis, v. 55, n. 9, p. 2579?2589, 2011.

Hyndman, R. J.; Athanasopoulos, G. Forecasting: Principles and Practice. 3. ed. Melbourne: OTexts, 2021. Disponível em: https://otexts.com/fpp3/

Hyndman, R. J.; de Livera, A. M.; Snyder, R. D. Forecasting time series with complex seasonal patterns using exponential smoothing. Journal of the American Statistical Association, v. 106, n. 496, p. 1513?1527, 2011.

Ji, A., Li, D., Dai, Z., Cui, M., Yu, L., & Duan, Z. (2025). A hybrid graph memory network approach with multi-level feature representation for traffic flow forecast. Expert Systems with Applications, 130316.

Kamarthi, H., Sasanur, A. B., Tong, X., Zhou, X., Peters, J., Czyzyk, J., & Prakash, B. A. (2024, August). Large scale hierarchical industrial demand time-series forecasting incorporating sparsity. In Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (pp. 5230-5239).

Lila, M. F., Meira, E., & Oliveira, F. L. C. (2022). Forecasting unemployment in Brazil: A robust reconciliation approach using hierarchical data. Socio-Economic Planning Sciences, 82, 101298.

Lu, X., Chen, C., Gao, R., & Xing, Z. (2023). Prediction of high-speed traffic flow around city based on BO-XGBoost model. Symmetry, 15(7), 1453.

Mu, H., Aljeri, N., & Boukerche, A. (2025). Hierarchical multi-scale spatio-temporal semantic graph convolutional network for traffic flow forecasting. Journal of Network and Computer Applications, 238, 104166.

Peden, M. M. (2004). World report on road traffic injury prevention. World Health Organization.
Qin, Y., Luo, H., Zhao, F., Fang, Y., Tao, X., & Wang, C. (2023). Spatio-temporal hierarchical MLP network for traffic forecasting. Information Sciences, 632, 543-554.

Rehman, H. U., Wan, G., & Rafique, R. (2023). A hybrid approach with step&8208;size aggregation to forecasting hierarchical time series. Journal of forecasting, 42(1), 176-192.

Silva, Alan Ricardo; Cavalcante, Rodrigo Nunes. Average speed dynamics on urban roads and highways: Influence of traffic infrastructure, vehicle and road characteristics on driving behavior. Case Studies on Transport Policy, p. 101591, 2025.

Silva, T. B. B., Bessa Jr, J. E., & de Oliveira, L. K. (2024). Evaluation of models for estimating free-flow speed on two-lane rural highways in Brazil. Latin American Transport Studies, 2, 100011.

Stoian, D., Spiliotis, E., Stamatopoulos, E., Sarmas, E., & Marinakis, V. (2025). Regularized reconciliation of hierarchical forecasts with application to building electricity demand. Energy and Buildings, 116711.

Sun, B., Sun, T., & Jiao, P. (2021). Spatio&8208;Temporal Segmented Traffic Flow Prediction with ANPRS Data Based on Improved XGBoost. Journal of Advanced Transportation, 2021(1), 5559562.

Wang, X., Hyndman, R. J., & Wickramasuriya, S. L. (2025). Optimal forecast reconciliation with time series ion. European Journal of Operational Research, 323(2), 455-470.

Wickramasuriya, S. L.; Athanasopoulos, G.; Hyndman, R. J. Optimal forecast reconciliation for hierarchical and grouped time series through trace minimization. Journal of the American Statistical Association, v. 114, n. 526, p. 804?819, 2019.

Xia, Q., Sun, Z., Zhang, H., Lin, Y., & Lu, Y. (2026). A multiscale decomposition and semantics-guided feature reconstruction LLM framework for traffic flow forecasting. Transportation Research Part C: Emerging Technologies, 186, 105633.

Yamashita, T. J., Wester, D. B., Wardle, Z. M., Scognamillo, D. G., Schofield, L. R., Tewes, M. E., ... & Lombardi, J. V. (2025). Influence of traffic volume on mammal beta diversity within the road effect zone. Biological Conservation, 311, 111428.

Yang, Y. Q., Lin, J., & Zheng, Y. B. (2022). Short-time traffic forecasting in tourist service areas based on a CNN and GRU neural network. Applied Sciences, 12(18), 9114.

Yang, Z., & Wang, C. (2023). Short&8208;term traffic flow prediction based on AST&8208;MTL&8208;CNN&8208;GRU. IET intelligent transport systems, 17(11), 2205-2220.

Yuan, J., Zheng, Y., Xie, X., & Sun, G. (2011, August). Driving with knowledge from the physical world. In Proceedings of the 17th ACM SIGKDD international conference on Knowledge discovery and data mining (pp. 316-324).

Zeng, H., Dong, C., Fu, R., Su, K., Leng, X., & Guo, C. (2025). A gated Recurrent unit considering spatial correlation for short-term traffic volume forecasting in highway tunnels. Engineering Applications of Artificial Intelligence, 159, 111796.

Zheng, Z., & Su, D. (2014). Short-term traffic volume forecasting: A k-nearest neighbor approach enhanced by constrained linearly sewing principle component algorithm. Transportation Research Part C: Emerging Technologies, 43, 143-157.

Zhou, J., Ding, W., Zhao, Z., & Li, H. (2019, August). SMART: a service-oriented statistical analysis framework on spatio-temporal big data (short paper). In International Conference on Collaborative Computing: Networking, Applications and Worksharing (pp. 91-100). Cham: Springer International Publishing.

Imagens do Projeto



Apêndice - página 1



Apêndice - página 2

Inovação Tecnológica

A pesquisa tem potencial para gerar inovação tecnológica? Ainda depende de avaliação

Comprovante gerado em 11/04/2026, às 11:35:47